


# AI/AIGC 数据清洗解决方案

## 1 场景与需求分析



### 1.1 业务流程分析

TODO：考虑外网数据抓取部分（从国外 Region 通过爬虫抓取数据转国内）

#### 数据的流转（Spark 流程）

网络爬虫 -> 网页数据打包

-> 通过公网数据进 SourceBucket

-> 数据清洗任务 1” 文本抽取 “从 SourceBucket 中读取数据 完成后 写入 TempBucket

-> 数据清洗任务 2” 文本处理 “从 TempBucket 中读取数据 完成后 写入 ResultBucket

-> 训练数据从 ResultBucket 读取，喂给 GPU 集群进行大模型训练

#### 数据清洗任务

1. 任务一：文本抽取（将爬取的网页转换为 JSON 格式的文本）

重 IO 任务：10000core 对应 600Gb~1000Gb 带宽

2. 任务二：文本处理（分语言，分句，分词，词性标准，谓词逻辑、语料评分）


重CPU任务：主要消耗CPU任务，KS3存储吞吐不是瓶颈

## 1.2 技术需求分析


XX项目训练数据集 Bucket 容量

| 空间名称           | 地区(ALL, 中国 (北京), 中国 (上海), 中国 (香港), 中国 (新加坡), 中国 (悉尼), 中国 (东京), 中国 (法兰克福), 中国 (伦敦), 中国 (首尔), 中国 (孟买), 中国 (悉尼), 中国 (东京), 中国 (法兰克福), 中国 (伦敦), 中国 (首尔), 中国 (孟买)) | 创建时间                | 存储类型(ALL, 标准存储, 低频存储, 归档存储) | 存储容量      | 访问权限(ALL, 默认读权限, 数据CTL) | 操作                                    |
|----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------|-----------------------------|-----------|-------------------------|---------------------------------------|
| spark-test2    | 中国 (北京)                                                                                                                                                      | 2024-01-08 15:12:29 | 标准存储                        | 2.41 PB   | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |
| mb-dw          | 中国 (北京)                                                                                                                                                      | 2024-03-07 11:11:01 | 标准存储                        | 234.18 TB | 数据CTL                   | <a href="#">详情</a> <a href="#">设置</a> |
| web-pipeline   | 中国 (北京)                                                                                                                                                      | 2024-02-29 11:05:16 | 标准存储                        | 51.62 TB  | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |
| parameters     | 中国 (北京)                                                                                                                                                      | 2023-05-20 15:50:12 | 标准存储                        | 12.36 TB  | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |
| audio-store    | 中国 (北京)                                                                                                                                                      | 2024-01-19 14:03:50 | 标准存储                        | 199.87 GB | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |
| spark-test     | 中国 (北京)                                                                                                                                                      | 2024-01-05 15:17:15 | 标准存储                        | 101.85 GB | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |
| registry-cache | 中国 (北京)                                                                                                                                                      | 2023-05-18 13:45:30 | 标准存储                        | 37.9 GB   | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |
| mb-images      | 中国 (北京)                                                                                                                                                      | 2023-06-28 16:41:59 | 标准存储                        | 1.46 GB   | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |
| openalproxy    | 中国 (北京)                                                                                                                                                      | 2023-08-02 13:05:25 | 归档存储                        | 4.44 MB   | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |
| mb-crawl-data  | 中国 (北京)                                                                                                                                                      | 2024-03-07 20:06:24 | 标准存储                        | 3.06 MB   | 数据CTL                   | <a href="#">详情</a> <a href="#">设置</a> |
| crawl-media    | 中国 (北京)                                                                                                                                                      | 2024-03-07 20:05:21 | 标准存储                        | 3.53 KB   | 数据CTL                   | <a href="#">详情</a> <a href="#">设置</a> |
| crawl-models   | 中国 (北京)                                                                                                                                                      | 2023-10-24 16:56:43 | 标准存储                        | 0 B       | 默认读权限                   | <a href="#">详情</a> <a href="#">设置</a> |

XX项目训练数据集 Bucket 吞吐



7天



48小时

大数据计算平台

## 弹性计算

## 高性能对象存储

# 2 基于 存算分离 / 存算一体 + 标准对象存储 解决方案

(中短期方案，24H1)

### 【存算一体方案】

- CPU 6240 18core\*2 内存：512GB，硬盘 10\*16TB
- 300TB 数据 ~ 36Core ~ 512GB
- **结论：100TB 数据 ~ 12Core ~ 128GB**

# 3 基于 存算分离 + 全闪对象存储 解决方案

(中长期方案，24H2，依赖全闪对象存储)

基于全闪对象存储 PB 级容量能够提供 Tb 级吞吐的超高性能，所有数据清理任务能够全部采用存算分离的架构执行。整个数据清理讲具备充分的计算和存储弹性，为客户提供更友好的体验和更高性价比。

### 【存算分离方案】

- 参考 面壁项目：400TB 数据 ~ 80 台物理机（32 核）~ 400Gb~600Gb 带宽
- 参考 小红书项目：2~3PB 容量 对应 4Tb 带宽 计算资源未知
- **结论（仅文本抽取任务）：CPU/ 带宽配比：10000core 对应 600Gb~1000Gb 带宽**

实例：面壁 100TBSpark 任务，吃满 7000 核，需要 400Gb~600Gb 带宽，完成时间 16 小时

待定问题：如果对于整个数据清理流程（任务一 + 任务二 + 任务三）

# 4 时间安排

- 2024.03 ~ 2024.06: 主推 存算一体 / 存算分离 + 标准对象存储 解决方案
- 2024.XX.XX: 全闪对象存储公测（KS2.6.0 版本上线）

- 2024.XX.XX: 全闪对象存储线上回归结果 按照读写 1: 1 计算, 达到 PL3 水平 (单 PB 容量兑付 1Tb 吞吐、读写比例 1: 1)
- 2024.XX.XX: 基于全闪对象存储的清洗业务模拟测试: 100TB 任务, 100Gb 吞吐, 1500 核, 耗时预计 ~60 小时
- 2024.XX.XX: 全闪对象存储线上交付能力 (四周内可交付) 达到 1PB (基于面壁项目推算典型客户肯可能运行任务所使用的容量), 全链路达到 PL3 水平以上, 最好 2 倍 PL3v2
- 2024.XX.XX: 默认推荐方案改为 存算分离 (盖亚) + 全闪对象存储方案