

数据清洗

智源

1. 智源是在洗视频 6PB，全部完成需要多久？按照 44 台 ~12 周
2. 4月7日 -4月12日
 - a. 物理机数目：71 台，配置是 8358P（64 物理核），25Gb*1
3. 按照一个任务，任务大小
 - a. 整个任务包括下载，计算，上传
 - b. 下载过程中的并发数目 每个 EPC KS3 Util 64 进程 *4 线程
 - c. 下载用时多久？下载多少数据？ 4 小时 * 150Gb/s = 263TB
 - d. 下载过程中的带宽截图



- e. 计算用时多久？


计算 task1 需要 20 个小时， task2 需要 10 小时，因为 task 是串行所以一共需要 30 小时

- f. 计算后保留数据量多大？

计算后保留 3% 的数据量，也就是 1P 数据会清洗剩余 30TB 的数据保存（根据目前客户清洗进度所得到的结论）

- g. 计算过程中 CPU 利用率多少？

计算过程中每台服务器 Spark 启动了 64 个进程进行数据清洗




h. 结果上传时间多久？峰值带宽多少？截图

用户使用 ks3 util 设定每台机器 500 个并发，集群并不是同时上传，而且有先后顺序。

目前 baai-vision-wudao 这个桶还在上传原始数据

i. 下载和上传过程中的 CPU 利用率

下载时间为晚上 8 点到第二天凌晨 12 点，CPU 利用率 100%



面壁

下载到存算一体，然后计算

计算场景是文本

存算一体集群配置

70 台 8358P 25Gb

下载时间，留存率，上传时间

数据留存率在 10% 左右




Figure 2. Subsequent stages of Macrodata Refinement remove nearly 90% of the documents originally in CommonCrawl. Notably, filtering and deduplication each result in a halving of the data available: around 50% of documents are discarded for not being English, 24% of remaining for being of insufficient quality, and 12% for being duplicates. We report removal rate (green) and kept rate (shaded) overall. Rates measured in % of documents in the document preparation phase, then in tokens.

一次任务约 500TB，拉多久？



使用 500Gb 带宽需要 2.3 个小时



下载用什么？distcp

一次任务算多久？

70 台 EPC，跑完 500TB 任务需要 51 个小时

计算过程中的 CPU 利用率

4/3 日到 4/5 日 CPU 利用率



上传多久？