

金山云面壁数据清洗项目交付方案

基本信息

客户：
面壁 UID：2000165551

项目名称：
AIGC 数据清洗

背景描述：
面壁作为 AIGC 创业公司，需要使用 common crawl 下载的数据进行数据清洗，清洗后的数据集用于大模型训练。
本次数据清洗任务作为 100B 模型训练的上游，用户计划每周清洗 40TB 数据作为模型训练的语料数据集

需求描述：
动态持续交付，峰值达到 20000 核。---TBC
大数据 KMR 平台提供基于裸金属 EPC 20000+ 核算力，以及 KS3 对象存储提供不低于 20PB 和 600Gbps 带宽能力

核心交付内容：
用户使用大数据 KMR 控制平台进行：

- EPC 裸金属集群进行开机扩容，要求用户可以顺利开机，构建 KMR 集群；
- 可以顺利基于现有 KMR 集群进行扩容操作

项目交付时间：
2024 年 3 月 15 日 之前交付 10000 核 KMR EPC 算力，未来随着数据清洗的业务量增加逐步扩容至 20000 核—TBC

💡 核心交付内容和交付时间是重点，必须清晰

项目需求

资源需求

- 💡
- 项目的明确的，完备的需求，完成所有项目需求中的交付项目，应该等价于项目交付完成
 - 可以不采用表格的形式，逐条列出即可
 - 要求是完备的，明确的。
 - 特别注意隐含的关联需求，比如需要云主机的，基本上也需要云网络，EIP 等。
 - 理论上要把所有产品都确认一遍，千万不是客户提出什么就认为只需要交付什么

大类	产品	需求	交期要求	承诺交期	备注
计算	EPC	20000 核	持续交付		本次交付不是一次性交付，根据用户对于算力的需求，最终扩容至 2 个 KMR 集群共 20000 核算力
存储					
	KS3	20PB	持续交付		本次交付不是一次性交付，根据用户对于存储的需求，最终扩容至 20PB
大数据	KMR	Spark	持续交付		

功能需求

💡 重点的功能需求、影响交付的功能需求、尚且不具备需要开发的功能需求

用户在项目交付的中后期，要求金山云提供基于 serverless 形态的计算算力的需求。

交付风险

💡 逐条详细列出该项目需求交付可能存在的风险

对于所有风险项，要有明确的解决方案、负责人，解决的时间点

1. EPC 备货是否按需及时满足用户的预期，负责人，陈亮，时间，陈永杰

解决方案：

根据用户对于算力的弹性需求，结合我云目前资源供给和产品形态，我们提出以下两种解决方案满足用户需求：

- a. 用户弹性需求，计划8月提供基于 serverless spark 的算力池，从而满足用户对于弹性算力，以及易用性的需求
- b. 维护基于 EPC 的 KMR 算力池，满足用户常态数据清洗算力需求，用户对于算力池的扩容需求，需要提前提出需求，主机团队进行备货，大数据产品上线，用户开机

2. EPC 主机raid 卡配置是否正确，负责人陈亮，时间，陈永杰

解决方案：

- a. 裸金属参照大数据提供的明确需求固定配置，确认实际配置与需求配置完全相符，其中本地盘配置固化：系统盘做 raid1，数据盘做 SRaid0；在保障服务性能的同时减少因配置差异产生的开机失败概率
- b. 配置不满足需求、非标准套餐、尤其是数据盘无法做 Sraid0 的服务器原则上不接受
- c. 如果用户特殊需求或受限于客观因素出现非标机型配置需求，需要同时由销售 / 售前同步客户侧明确接受可能的风险，另外内部将相关评估情况前置同步至相关领导

3. EPC 主机是否存在因为各种原因开机失败的可能

解决方案：

- a. 快速感知：售后交付已对接云监控事件告警，有大数据产品涉及的 EPC 相关事件告警出现时，第一时间同步大数据侧运维 --@王嘉楠 向售后团队同步 KMR 标准主机名称及告警出现同步流程和对象
- b. 主动发现：评估并确认，替换覆盖写检查盘问题的其他方法，主动发现盘硬件 IO 下降问题 --@陈永杰 6.18 反馈方案
- c. 用户侧提示：KMR 官网文档更新，建议用户接入云监控事件监控 & 硬件报警 --@SHI JIAN 6.11 完成
- d. 处理效率提升：与 EPC 合作，新增一键授权流程，授权大数据及时处理问题，避免客户授权事件对处理过程的效率影响@SHI JIAN 6.13 反馈解决方案 & 上线时间

交付日志

💡 按天记录交付日志

每天的进展

与客户的沟通记录


风险点的跟进情况

2024 年 7 月 18 日

拉通前后端明确未来 6240 raid 卡交付方式，未来不接收只能做 2 组 raid 的 HBA 卡，该做法会延长交付时间。



谭肇宏：



没问题

更换Raid卡，支持SRaid0 cc@SHI JIAN



孙元美：更换Raid卡，支持SRaid0 cc@SHI JIAN

@王嘉楠 @侯雪峰 @陈亮 知悉



昨天 14:56

昨天 14:56



2024年7月16日

和研发，主机以及 PM 进行沟通，目前交付的 6240EPC 使用 raid 卡做全盘 raid0，会导致数据恢复数据量较大会对用户业务产生影响。

讨论了各种可能性：

- 换 raid 卡 - 成本原因不可行
- 使用现有 raid 卡做多组 raid，本周进行测试，如果可行，未来交付的 6240KMR 集群使用这种方式交付 - 现有 6240 匹配的 HBA 卡，只能做一组 raid

针对现有已经交付的 6240 KMR 集群，使用全盘 raid0 方案，从而保证集群的磁盘 IO 性能一致，避免卡 IO 的情况发生。

2024 年 7 月 15 日

昨天项目运行进展正常，无故障运行

今天前往客户现场拜访，记录如下：

- 【待交付】客户目前确认有 400TB 多模态数据从美国阿里传回北京阿里，未来用户计划拉一根 10Gb 专线把数据从阿里云传回 KS3
 - 专线 7 月 16 日陈涛报价 - 已完成
- 用户未来还有 800TB-1P 多模态数据清洗需求，数据来源 - 阿里云，未来计划复用该专线，将数据回传至 KS3
- 【待交付】用户未来希望使用金山云新加坡资源进行海外数据抓取，需求细分如下：
 - 20 台云主机，300 核数
 - 15 块 EBS 盘，1.5GB/s 带宽
 - 5Gb/s 回国专线明天和 PM 确认资源交付方案以及报价给用户 - 已完成
- 和用户介绍了未来弹性算力资源池 serverless 的方案，以及全闪存 KS3 的产品能力，未来继续跟踪
- 【待交付】本周用户计划扩容 34 台 EPC（6240）持续进行，多模态数据清洗
 - 资源已经交付，本周等待用户开机。周三和用户二次确认。

2024 年 4 月 12 日

项目稳定运行

2024 年 4 月 11 日

项目稳定运行

2024 年 4 月 10 日

项目稳定运行

2024 年 4 月 9 日

项目运行稳定

2024 年 4 月 8 日

32 台机 EPC 完成改配，加入用户加入存算一体集群，集群规模 91 台 EPC 8358P

2024 年 4 月 7 日

用户缩容 32 台机器，即将完成改配，计划 1 到 2 天完成重新加入存算一体集群。

2024 年 4 月 3 日

用户已经跑完 500TB Mapreduce 任务没有错误

今天完成 32 台 8358p 缩容，未来计划改配

高性能计算型 -II-I-VIII 8358P*2（64 核 128 线程） 1024G SATA3.5_16T*4 25G_2 * 1

高性能计算型 -II-I-VII 8358P*2（64 核 128 线程） 1024G SATA3.5_16T*12 SATA2.5_240G*2
25G_2 * 1；

计划 4 月 8 日重新加入集群。

2024 年 4 月 2 日

完成存算一体集群扩容，目前用户集群 91 台 8358P（core 节点）2 台 6240（master 节点），
hdfs2 副本之后，集群可用容量 3.4 TB。目前客户任务正常运行中。

2024 年 4 月 1 日

周日完成存算分离集群节点改配，今天下午重新加入存算一体集群，引导用户开集群。

面壁在新加坡开了 6 X6 台云主机，作为代理访问国外一些网站，生成 KB 级别报文并通过公网
回传，上周稳定运行，对于存储和网络上没有性能要求。

2024 年 3 月 29 日

用户存算分离集群已经停机下线进行改配置，预计周一中午前交付，改配完成后开机加入存算
一体集群。

2024 年 3 月 28 日

上午和用户沟通将存算分离集群中的节点下架改造加盘后重新加入到存算一体的集群，改造过程需要最多三天。用户原则上同意该方案。整个过程中存算一体的业务会持续保持运行。

面壁-清洗集群切换方案

- MapReduce 任务：目前任务主要是下载 500T 数据到存算一体集群上。
- Spark 任务：接下来用户会将这上面的任务都迁移到存算一体集群上。

2024 年 3 月 27 日

任务：

- MapReduce 任务：昨晚用户尝存算分离方式进行任务处理，KS3 流量一度速触发任务失败 (socket is reset)。我们这边建议用户使用批量下载后再处理的存算一体方式继续跑任务。用户认为这种方式可行。和用户明确了 KS3 资源带宽上限，用户计划先下 500T 数据，之后本地进行处理。接下来，我们逐渐将用户存算分离的主机逐渐改配加盘加入存算一体的集群，未来数据数据都存在 HDFS 上。

- Spark 任务：迭代 snapshot 未报异常


2024 年 3 月 26 日

任务：

- MapReduce 任务：用户完成 160TB MapReduce 任务，用时 40 小时。今天用户运行 194T 任务, 预计 60 个小时。
- Spark 任务：迭代 snapshot 未报异常

资源：

KS3 带宽过去两天资源利用率相对较低。



2024年3月25日


任务：

- MapReduce 任务：用户 160TB MapReduce 失败，经过排查是因为 HDFS 数据分布不均匀造成的，重新 Balance 数据之后，业务恢复正常。未来计划使用 30 台满配磁盘节点替换集群中磁盘数量较少节点从而彻底解决此类问题。
- Spark 任务：用户已经跑通一个 snapshot 的整个业务流程，接下来用户开始轮训 Snapshot。

目前核心的矛盾点是：用户开了有限的资源，但是提交了大量的任务，算力满载导致部分业务提交 / 运算失败，客户认为这是我们 IaaS/PaaS 的问题。

资源：

经过存算一体改造后，过去 2 天 KS3 带宽用量已经趋近于稳定



今天给面壁用户在新加坡开了 1TB EBS SSD 3.0 满足用户需求，短期用户没有 EBS 的需求

2024年3月23-3月24

周末帮助用户完成了存算一体集群扩容，升级之后目前已经跑通：

- 50TB MapReduce 任务
- 100TB MapReduce 任务（第一步生成 104T 数据，第二步生成 10T 数据）

接下来用户准备使用存算一体集群跑 160TB MapReduce 任务，目前帮助用户将数据从 KS3 上同步到存算一体集群之后开始跑任务。

目前来看使用存算一体集群 1500 核，跑 100TB 任务，耗时 32 小时。

2024年3月22日

本周工作总结：

目前已经跑通的核心任务：

- 100T Spark 任务
- 70T MapReduce 任务

目前 100TB MapReduce 任务在存算一体的集群出现 APP Master OOM 的问题。经过分析是用户脚本参数的问题，研发配合用户一起调整。


用户建议将存算分离集群的 39 台机器加入到存算一体中从而加速 MapReduce 任务效率，我们尽快配合用户改造集群。

2024 年 3 月 21 日

今天 12 台 EPC 加入 KMR 集群，部署存算一体解决方案，下午用户将 MapReduce 业务切换到存算一体的集群中，计划先按照 100T 数据规模进行清洗。通过这种方式进一步提升数据清洗效率，降低对于存储的带宽需求压力。

2024 年 3 月 20 日

梳理用户业务已经完成



用户核心清洗任务分为 Spark 和 MapReduce 任务

- 目前 Spark 任务第一个阶段已经跑完 100TB 数据，接下来会跑第二第三阶段（ccnet），之后会等比放大评估 8P 数据清洗需要时间
- MapReduce 任务一直没有跑通，白天研发和用户进行排查，目前来看瓶颈在于用户脚本实现逻辑
- 明天会按照用户要求交付 12 台 EPC 搭建存算一体方案，未来计划将 MapReduce 任务切换到存算一体架构下，进一步提升清洗效率

2024 年 3 月 19 日

部署 GAEA 之后业务运行平稳，偶尔见到任务失败，分析之后是用户业务脚本逻辑的问题。

昨晚 KS3 带宽从 200Gb 升级到 400Gb，夜间任务将带宽完全吃满，100TB 量级的任务，10 个小时进展 10%，预计 4 天可以跑完。今天下午 6 点 pgw 切换至 p4 型号，下午用户任务以计算为主已经基本上跑满 KMR EPC 的 CPU。今晚到明天凌晨，KS3 会临时提升带宽至 600Gb。

晚上和面壁的项目组进行了沟通，了解到用户清洗数据的周期是 4 个月。

我们给用户建议白天的时候跑计算密集型业务，夜间跑 IO 密集型业务。用户计划用一部分数据集跑通全部业务，并以此为依据，评估在现有资源下，8PB 数据清洗说需要的时间是否符合项目预期。

于此同时，我们这边会准备 10 台 EPC 搭建新的 KMR 集群，使用存算一体的方案承载部分用户数据集的清洗任务，从而加速整体清洗速度。

2024 年 3 月 18 日

今天下午拜访面壁，将过去半个月出现的问题和用户进行复盘和总结。

针对客户之前出现的 10 个问题进行说明，同时告知我们针对金山 KS3—HDFS 方案，单目录下多文件读取性能差（几十万 - 百万个）进行了架构升级目前计划使用替代方案，在客户集群部署 gaea 服务（基于 alluxio 带计算节点的版本）gaea 可以有效的解决此类问题，数据流操作均在计算节点进行操作，跟 master 节点之间只有元数据操作。

未来用户担心我们的清洗进度会影响到他们下一次训练计划，用户给了我们到本周 5 作为最后时间点，在此之前我们会有研发和解决方案的同事驻场现场解决问题。

会后同时解决用户的其他诉求：

- 1. 客户希望监控所有 KMR 节点的 CPU、内存等监控。（客户希望根据实际使用情况调整 KMR 的任务数量，压榨集群的计算能力达到最大可用）

现场已经指导客户使用 Dashboard 实现。
- 2、客户希望在 HDFS 层面操作删除后，能有回收站功能。保障数据可以进行误删除回复。

因目前底层是 KS3 可以通过 KS3 回收站功能实现。但目前已经开启了 shadowcopy 功能，和回收站功能冲突。（都是元数据层级的操作，无法同步开启）。

下午在和用户解决问题过程中，我们发现：

- 目前来看桶的限速，对于 spark 任务影响比较大，任务会超时导致失败。现在看 2 个任务都是这么失败的。目前给面壁的限速是 200gb，用户计划晚起一个 300T 的任务。我们夜间放开限速最大到 400gb。晚上和用户一起进行任务启动，来观察是否可以解决用户的问题。
- 裸金属单节点带宽达到 15Gb，触发 pgw 限流丢包，这也可能是 spark 任务失败的原因。

大数据侧优化进展：

- 已将部署 gaea 服务部署到客户集群，经过客户任务验证（使用 ks3-hdfs 时该任务会卡主），**有效解决任务卡主问题**。该任务清洗时会加载 75 万个文件，35TB 数据。

交付结果

 实际完成交付的时间，交付的所有内容，客户反馈，问题的总结

见以上几项，此处不赘述