

面壁数据清洗

1.用户目的

用户的模型达到了千亿的参数规模，每周产生 40T 的数据，需要帮助客户产生 40T 的语料数据集。

2.资源

IAAS 层

计算：裸金属 8358P 6240

网络：PGW 是 EPC 的出口 每台 12 个 25G，KGW 是 ks3 的网关（可能会遇到带宽瓶颈）

存储：存算一体和存算分离两种方案

存算一体是 EPC 里加盘 12 块 16T 的盘 还有两副本，数据本地化，优势是性能比较好，但是价格更高

存算分离是数据放在 ks3 上，用的时候拉在本地，所以本地不用放太多的盘（拉数据时，需要考虑带宽，并行计算时，会有任务失败的方案，这时我们就应该给客户存算一体的方案）

PAAS 层

kmr 大数据集群用来业务管理，资源管理

1. yarn 是集群资源的管理和调度方式
2. 用户可以用 spark 和 mapreduce 大数据分布式处理的框架负责计算任务，如果使用 ks3，数据先拉到本地，再并行计算，生成计算结果
3. ks3-hdfs 缓存元数据（文件目录）

3.数据清洗方案

